課程：深度強化式學習

提升複雜社交場景下的機器人導航成功率

基於 SAC 與課程學習的深度強化學習方法

7114093001 郭乃文	7114064002 方芯芸
7114093009 李宗穆	7114064165 林奇和

NotebookLM

簡報大綱

01
Introduction (緒論)

揭示複雜社交場景中，機器人導航面臨的雙重挑戰與痛點。

02
Related work (相關研究)

剖析現有導航技術（基於規則與標準DRL）的演進與極限。

03
Proposed design (系統架構與設計)

深入探討 CS-SAC 框架三大核心機制的系統設計。

NotebookLM

緒論：社交導航的典範轉移

過去：單純避障

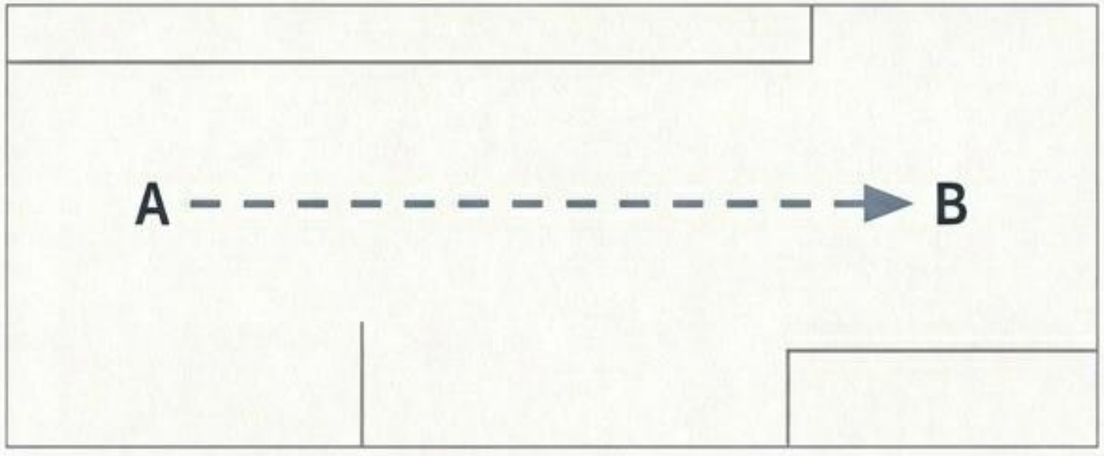

現在：社交合規決策

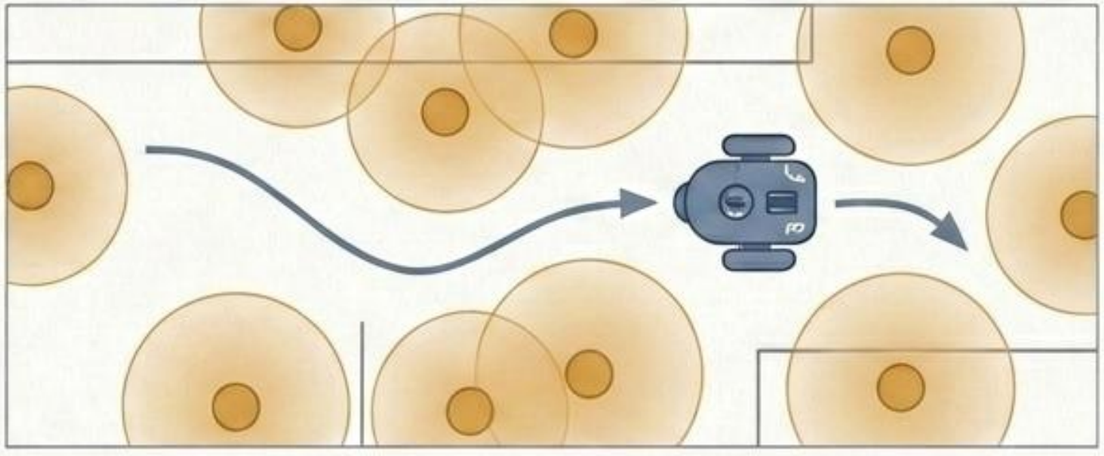

核心挑戰

服務型機器人步入公開場所，導航任務需同時兼顧安全性、效率與人類社交規範。

資料支撐與領域成熟度

累積 4,427 條軌跡與 4,402 筆人工評分樣本，全面進入系統化訓練與嚴謹比較階段。

學習式導航的突破潛力

基準測試顯示，在擁擠場景中表現亮眼：

- 成功率提升 38.3%
- 社交合規性提升 46%

[1] Social robot navigation: a review and benchmarking of learning-based methods (2025). Research Collection ETH Zurich.
[2] Towards Data-Driven Metrics for Social Robot Navigation (2025). arXiv. [3] SocialNav: Training Human-Inspired Foundation Model for Socially-Aware Robot Navigation (2026). arXiv.
[4] Robot Social Navigation with VLM-Informed Path Selection (2026). arXiv. [5] E-SocialNav: Efficient Socially Compliant Navigation (2026). arXiv. [6] Social robots global market report (2026). GII.

NotebookLM

緒論：現有系統的兩大瓶頸

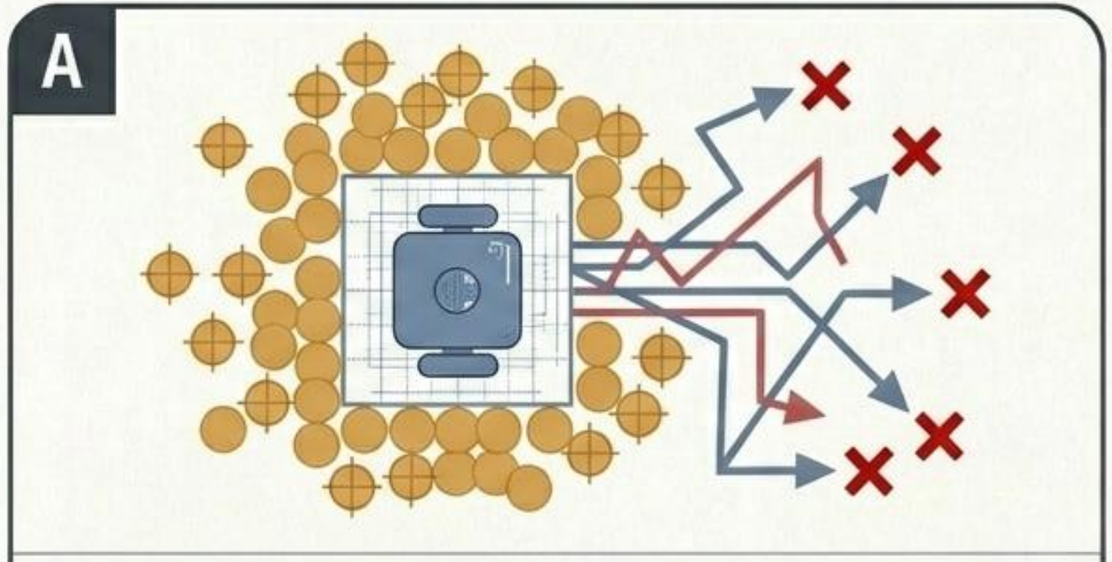

瓶頸一：機器人凍結 (Freezing Robot)

傳統基於規則的演算法在密集動態人群中過於保守，頻繁找不到可行解，導致機器人停滯或任務超時。

瓶頸二：學習陷阱 (Learning Trap)

深度強化學習 (DRL) 在處理高維度動態特徵時，極易在訓練初期掉入局部最佳解，導致收斂困難與泛化性低。

本研究對策：提出 CS-SAC 框架（注意力機制 + 課程學習 + SAC），系統性突破此兩大困境。

NotebookLM

相關研究：導航技術流派演進

基於規則之模型 (Rule-based)

代表技術: ORCA, SFM

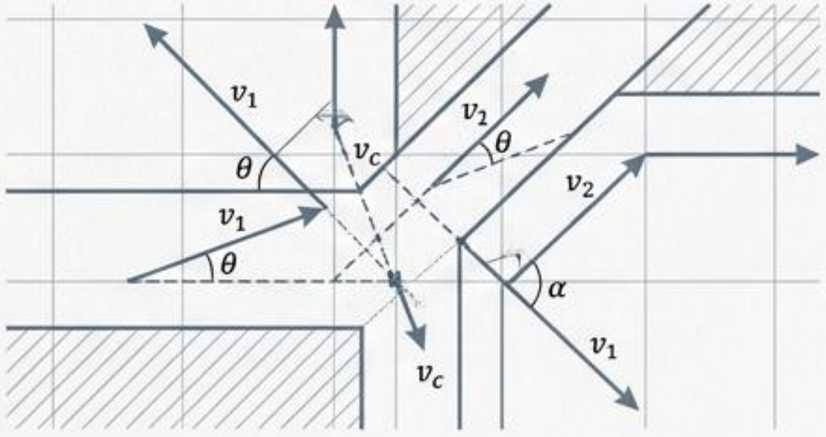

運作機制

依賴幾何運算與運動學公式，具備極高運算效率與數學嚴謹性。

致命缺陷

過度假設行人完美合作。擁擠場景極易觸發「機器人凍結」，輸出需經 PID 轉換才能連續控制。

標準深度強化學習 (Standard DRL)

代表技術: Vanilla SAC, DDPG

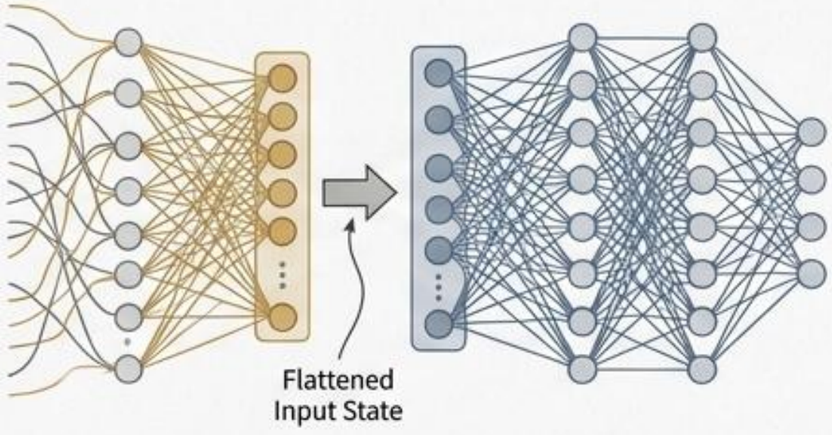

運作機制

採用無模型 (Model-free) 端對端訓練，打破規則限制，增強避障彈性。

致命缺陷

暴力拼接 (Flatten) 高維行人資訊會破壞空間「置換不變性」，極易掉入 U 型陷阱導致任務超時。

[1] Social robot navigation: a review and benchmarking of learning-based methods (2025). Research Collection ETH Zurich.
[2] Towards Data-Driven Metrics for Social Robot Navigation (2025). arXiv.

NotebookLM

相關研究：技術維度綜合對比

單一注意力機制模型（如 SARL）：引入注意力解決特徵提取，但因「缺乏階段性訓練引導」，面對複雜環境收斂極慢。

	處理動態高維特徵	避免局部最佳解	軌跡平滑與連續控制	收斂速度
Rule-based Models	✗	✗	—	✓
Standard DRL	—	✗	—	—
Single Attention (SARL)	✓	—	—	✗
CS-SAC (Proposed)	✓	✓	✓	✓

[3] SocialNav: Training Human-Inspired Foundation Model... (2026). arXiv. [4] Robot Social Navigation with VLM-Informed Path Selection (2026). arXiv.
[5] E-SocialNav: Efficient Socially Compliant Navigation (2026). arXiv.

NotebookLM

系統架構與設計：MDP 基礎問題定義

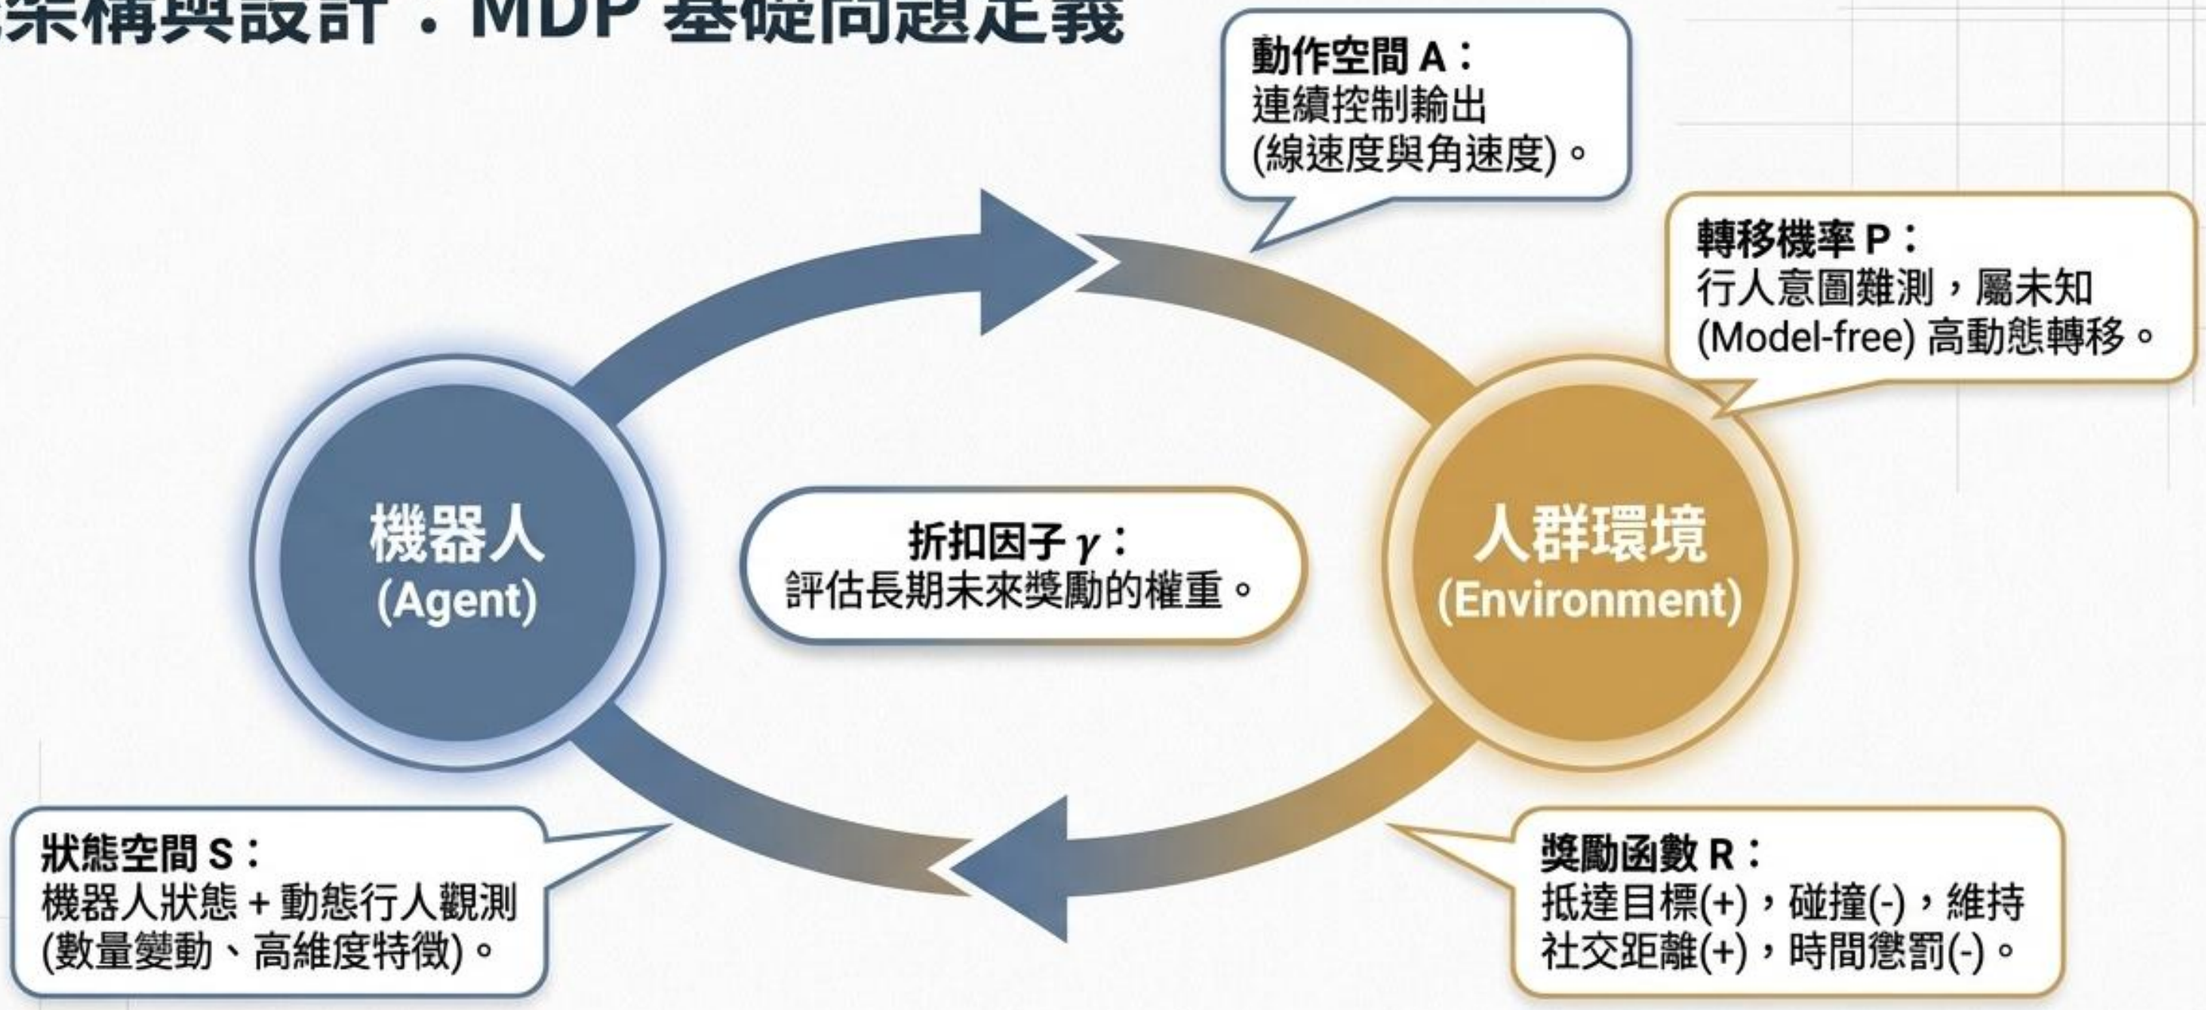

傳統 MDP 架構瓶頸

無法直接處理狀態空間 S 中的「數量變動」與「高維度」行人特徵，導致無法找出最佳導航策略。

NotebookLM

系統架構與設計：CS-SAC 核心架構

環境狀態輸入 (S)

01. 特徵提取優化

注意力權重 (AW) 網路

動態計算行人相對重要性，解決高維與數量變動狀態 S 的處理瓶頸。

02. 訓練機制突破

課程學習排程器

階段性任務拆解，由簡入深，解決盲目探索導致的局部最佳解與超時問題。

03. 連續控制效能

最大熵 SAC 核心

強化探索多樣性以應對未知轉移機率 P，輸出高度平滑與安全的動作 A。

連續動作輸出 (A)

NotebookLM

組件解析 01：注意力權重 (AW) 網路

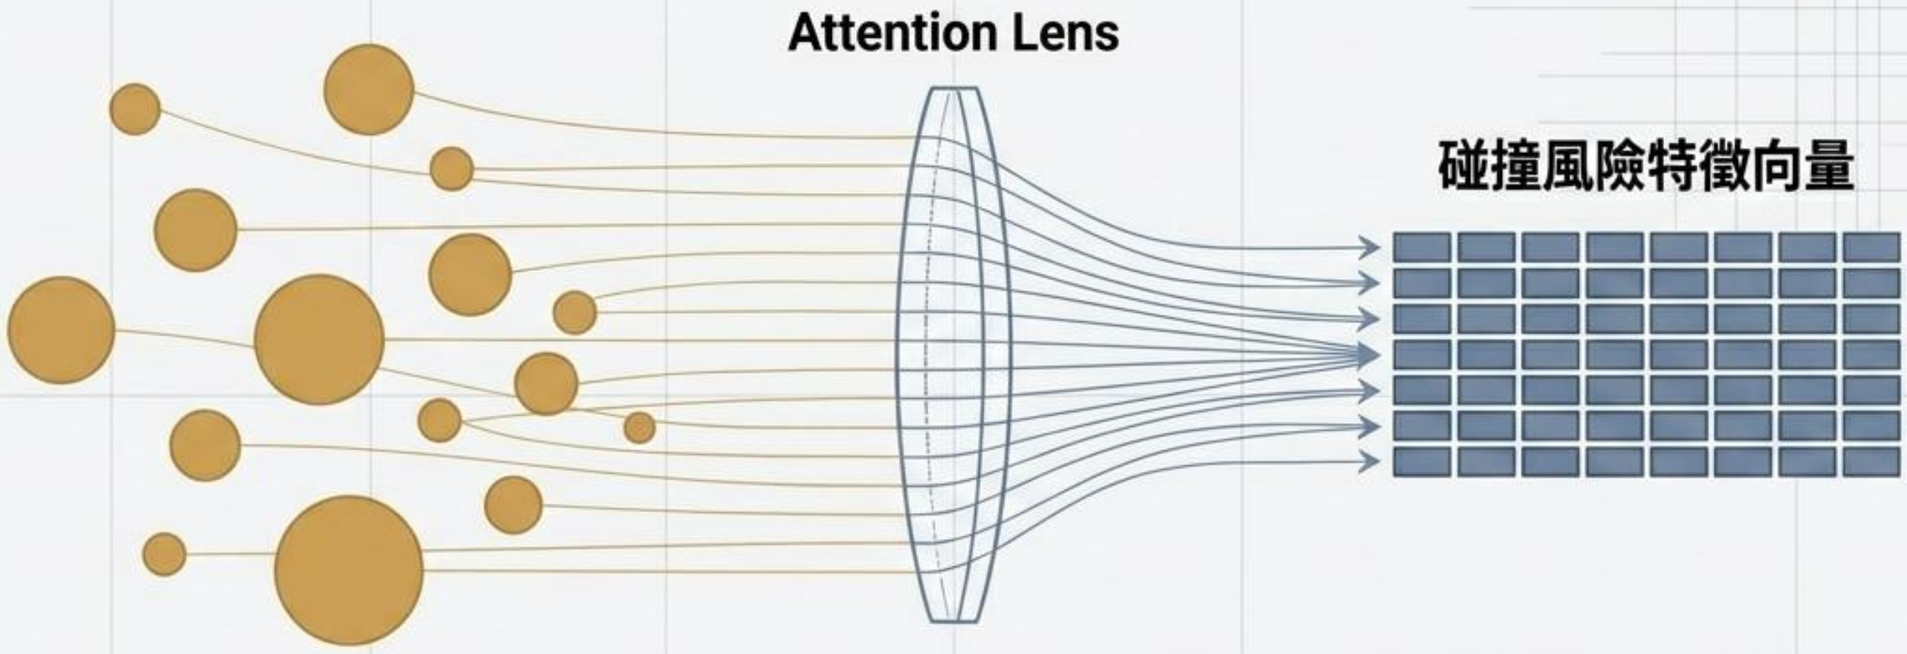

傳統痛點

將環境資訊暴力拼接 (Flatten)，讓模型失去對空間「置換不變性」的理解。

AW 網路機制

動態計算周圍每個行人對機器人的相對重要性與潛在碰撞風險。

突破成效

成功將變動數量的行人狀態壓縮為固定維度的精煉特徵，為策略網路提供最佳狀態輸入。

NotebookLM

組件解析 02：課程學習排程器 (Curriculum Learning)

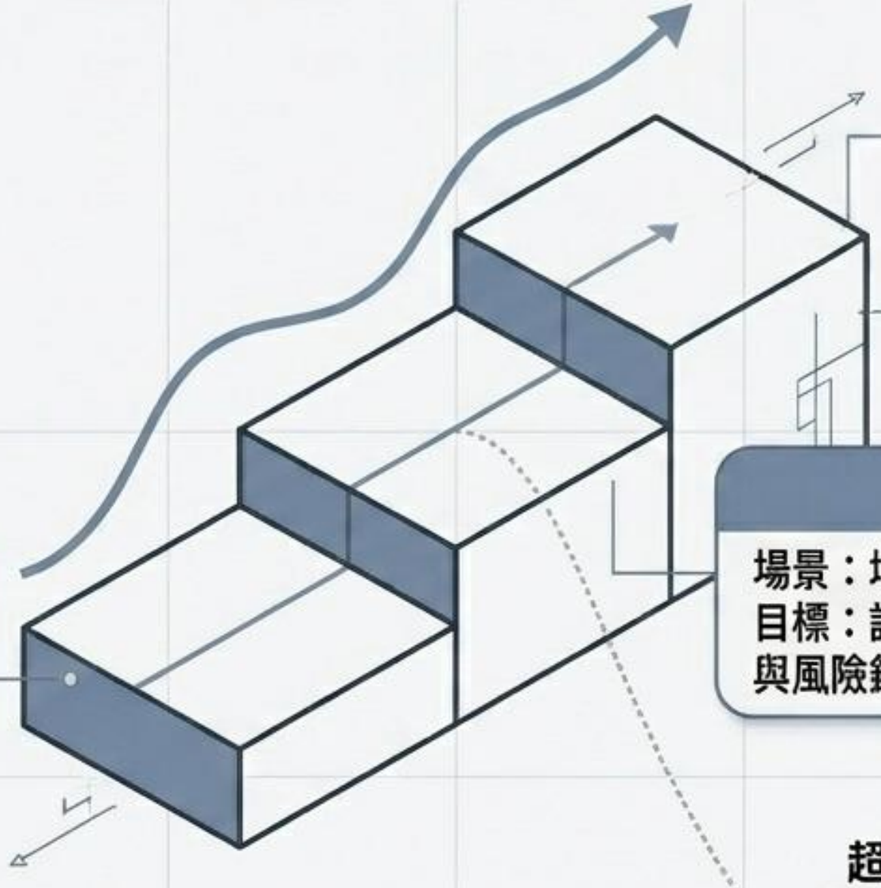

階段一：初階

場景：靜態障礙物與少量低速行人。
目標：建立基礎的目標達成能力。

階段二：中階

場景：增加行人密度與隨機路徑。
目標：訓練 AW 網路的高效特徵識別與風險鎖定能力。

階段三：高階

場景：高密度、非合作性行人交錯場景。
目標：強化極端情況下的社交合規性與避障韌性。

超時陷阱
(局部最佳解)

總結：透過由簡入深的排程，徹底避開盲目探索導致的學習崩潰，確保迅速收斂至全局最佳解。

NotebookLM

組件解析 03：最大熵 SAC 核心

標準 RL 動作輸出

SAC 核心動作輸出

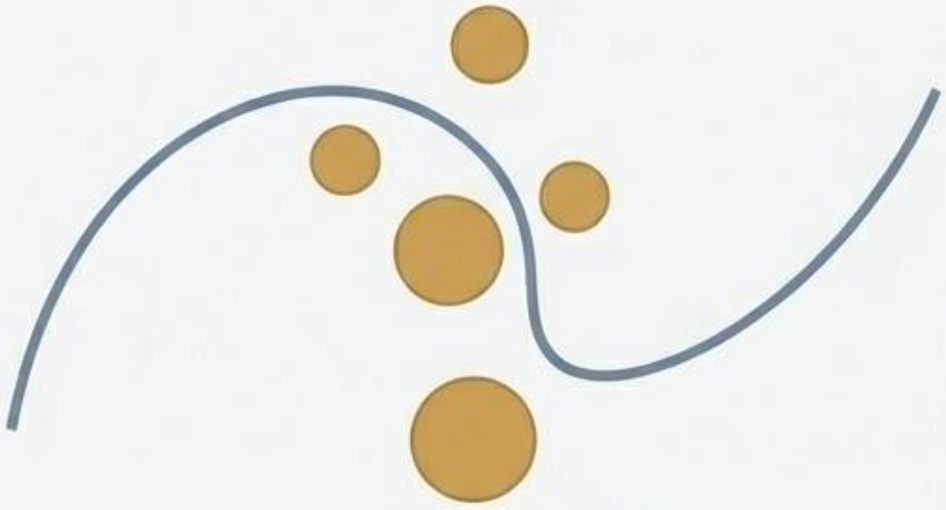

核心機制：最大化策略熵（Entropy）

在目標函數中引入「熵」的獎勵，鼓勵機器人在探索過程中保持動作決策的多樣性。

連續控制優勢

1. 穩定性：提升對高動態、未知環境轉移機率 P 的適應力。
2. 平滑度：確保連續動作空間（線速度與角速度）的控制指令極度平滑。
3. 安全性：軌跡更符合人類直覺的社交安全距離。

NotebookLM

總結：重新定義複雜場景導航

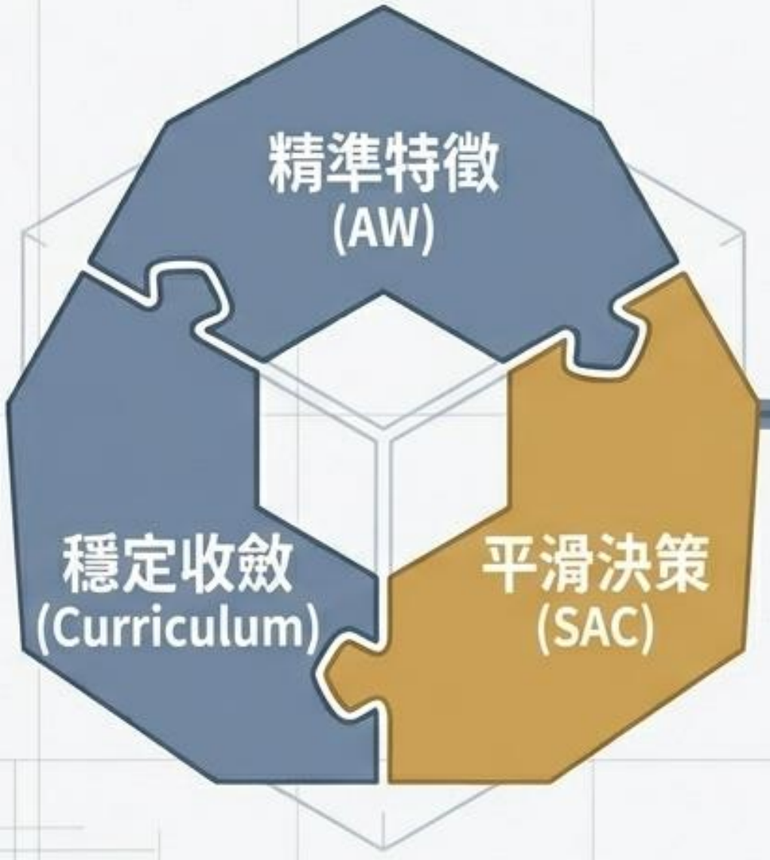

+38.3%
導航成功率提升

+46%
社交合規性提升

系統性突破：CS-SAC 完美解決了機器人凍結與學習陷阱，展現了將資料驅動與進階強化學習結合的強大實證價值。

在高度複雜的真實社交場景中，重新定義機器人導航的安全性與效率。

NotebookLM